

Tìm hiểu và triển khai kiến trúc Hierarchical Transformer cho bài toán sửa lỗi chính tả tiếng Việt

Nguyễn Ngọc Bình An
Nguyễn Đình Phú
Nguyễn Đoàn Nhật Minh
Phạm Lê Việt Đức

Học phần: Xử lý ngôn ngữ tự nhiên và dữ liệu lớn
Giảng viên hướng dẫn: TS. Trần Hồng Việt

Tổng quan nội dung

- 1 Đặt vấn đề và mục tiêu
- 2 Tập dữ liệu và tiền xử lý dữ liệu
- 3 Kiến trúc mô hình Hierarchical Transformer
- 4 Kỹ thuật tối ưu hóa và huấn luyện mô hình
- 5 Kết quả thực nghiệm
- 6 Triển khai ứng dụng Web Demo
- 7 Khó khăn, thách thức và hướng phát triển
- 8 Tổng kết

1. Đặt vấn đề

- Sửa lỗi chính tả tự động là bài toán nền tảng trong NLP, đóng vai trò là module tiền xử lý thiết yếu cho các hệ thống OCR, ASR, dịch máy và tìm kiếm thông tin.
- Tiếng Việt là ngôn ngữ đơn lập, giàu thanh điệu (6 thanh) và có hệ thống dấu phụ phong phú, chủ yếu được nhập liệu qua bộ gõ gián tiếp (Telex, VNI).
- Vấn đề: Lỗi chính tả phát sinh đa dạng (gõ phím kề, nhầm hỏi/ngã, lẫn phụ âm đầu, teencode) làm sai lệch ngữ nghĩa câu và giảm chất lượng dịch vụ.
- Thách thức: Cần mô hình gọn nhẹ, tốc độ suy luận nhanh theo thời gian thực nhưng vẫn nắm bắt được cả hình thái ký tự và ngữ cảnh ngữ nghĩa câu.

1. Mục tiêu

Xây dựng một hệ thống sửa lỗi chính tả tiếng Việt tự động dựa trên kiến trúc Transformer phân cấp gọn nhẹ, có khả năng phát hiện và khôi phục từ đúng theo thời gian thực.

- **Kiến trúc phân cấp:** Kết hợp trích xuất đặc trưng hình thái ký tự cục bộ và ngữ cảnh ngữ nghĩa toàn câu 2 chiều.
- **Tối ưu tài nguyên:** Thiết kế cấu hình $\approx 1M$ tham số có thể huấn luyện và phục vụ tốt trên GPU/CPU phổ thông.
- **Tập dữ liệu lớn:** Xây dựng pipeline dữ liệu sạch 4,66 triệu câu từ Wikipedia tiếng Việt và kiểm soát chống rò rỉ dữ liệu.
- **Ứng dụng thực tế:** Đóng gói hoàn chỉnh hệ sinh thái từ huấn luyện đến ứng dụng Web tương tác người dùng.

2. Tập dữ liệu

- Nguồn dữ liệu: Trích xuất từ kho văn bản sạch **Wikipedia tiếng Việt** (~ 2 GB text thô).
- Kiểm soát rò rỉ dữ liệu: Loại bỏ hoàn toàn các bài viết thuộc tập benchmark chuẩn **Viwiki-Spelling**.
- Phân chia độc lập theo page_id:
 - **Tập Train:** 4.564.618 mẫu (6,04 GB JSONL).
 - **Tập Validation:** 94.836 mẫu (124 MB JSONL).
- Không gian từ vựng: 9.500 từ vựng và 400 ký tự đơn lẻ.

2. Quy trình sinh nhiều tổng hợp

Áp dụng 10 toán tử sinh lỗi mô phỏng các hành vi sai sót thực tế:

- **Nhóm lỗi do gõ phím (52%):**


- Gõ sai phím dấu Telex (18%) và VNI (8%).
- Bấm nhầm phím kề bàn phím (12%).
- Thiếu ký tự (8%) và hoán vị ký tự liền kề (6%).

- **Nhóm lỗi ngữ âm và dấu thanh (38%):**

- Mất dấu thanh (12%) và mất toàn bộ dấu phụ (10%).
- Nhầm lẫn dấu hỏi và ngã (10%).
- Nhầm lẫn phụ âm đầu tương đồng (6%).

- **Nhóm viết tắt và ngôn ngữ mạng (10%)**

3. Kiến trúc mô hình



3. Chi tiết các khối kiến trúc

- **Character Encoder (2 lớp, $d = 64$):** Tích hợp cơ chế Masked Mean Pooling để nén các ký tự thành vector hình thái $\mathbf{O}_i \in \mathbb{R}^{64}$ cho từng từ.
- **Feature Fusion:** Ghép nối $[\mathbf{E}_{\text{word}}; \mathbf{O}_i]$ và chiếu tuyến tính sang không gian 128 chiều.
- **Word Encoder (4 lớp, $d = 128$):** Nắm bắt ngữ cảnh ngữ nghĩa 2 chiều trên toàn bộ câu.
- **Dual Output Heads (Đầu ra đa nhiệm):**
 - **Detector Head:** MLP 2 lớp phân loại nhị phân $\{0, 1\}$ (đúng / sai).
 - **Corrector Head:** Phân loại trên 9.500 từ vựng, áp dụng Weight Tying với ma trận Word Embedding.

4. Kỹ thuật tối ưu hóa tài nguyên

- **ALBERT Weight Sharing:** Dùng chung 1 khối Word Transformer cho cả 4 lớp → Tiết kiệm 75% tham số tầng từ.
- **Weight Tying:** Chia sẻ ma trận nhúng từ làm ma trận phân loại đầu ra → Tiết kiệm 608.000 tham số.
- **Streaming DataLoader (bucket=4096):** Đọc stream trực tiếp từ đĩa → Triệt tiêu nguy cơ tràn RAM trên tập dữ liệu 6 GB.
- **Mixed Precision (FP16):** Giảm 50% VRAM tiêu thụ và tăng tốc tính toán trên GPU.
- **Tổng tham số:** 1.001.310 tham số.

4. Huấn luyện mô hình

- **Hạ tầng phần cứng:** 1x GPU NVIDIA Tesla T4 (16 GB VRAM) trên Kaggle.
- **Siêu tham số:** 10 Epochs, Batch size 64, AdamW ($lr = 10^{-4}$, $weight_decay = 0.01$).
- **Learning Rate Schedule:** Linear Warmup qua 2 epoch đầu tiên.
- **Hàm mất mát:** $\mathcal{L}_{total} = \mathcal{L}_{det} + \mathcal{L}_{corr}$.
- **Độ hội tụ:** Giá trị Val Loss tối ưu đạt **1,5243** tại epoch 9.

5. Kết quả thực nghiệm

- **Hiệu năng phát hiện lỗi (Detector):**

- Precision: **92,43%** (Hệ thống rất hiếm khi gán cờ nhầm từ đúng).
- Recall: **83,27%**
- F1-Score: **87,61%**.

- **Hiệu năng sửa từ (Corrector):**

- Corrector Accuracy: **77,07%** khi đã phát hiện đúng vị trí lỗi.
- End-to-End Correction Recall: **74,95%**.

6. Triển khai ứng dụng Web Demo

- **Frontend (React + TypeScript + Vite: 5173):** Giao diện người dùng hiện đại, highlight lỗi trực quan, hiển thị gợi ý sửa từ và độ tin cậy.
- **Backend (FastAPI Server: 8000):** Cung cấp RESTful API, nạp checkpoint best.pt phục vụ suy luận thời gian thực.
- **Text Chunking:** Tự động chia đoạn dài (≤ 192 tokens), bảo toàn 100% định dạng khoảng trắng và xuống dòng.
- **3 chế độ nhảy:** Conservative (0.80), Balanced (0.50), Aggressive (0.30).

7. Khó khăn và thách thức

- Cơ chế phân loại 1–1 chưa giải quyết được lỗi dính từ (đi học → đi học) hoặc tách từ (b ảo → bảo).
- Vấn đề ngoài từ điển (OOV): Các thực thể tên riêng, từ mượn ngoại lai ngoài 9.500 từ vựng chưa thể khôi phục.
- Giới hạn phân đoạn (Chunking): Văn bản dài bị chia tách tại ranh giới 192 token, có thể giảm tính liên kết ngữ cảnh liên câu.

7. Hướng phát triển

- **Mở rộng kiến trúc giải mã (Seq2Seq / Subword):** Áp dụng Subword Tokenizer (BPE/Byte-level) để triệt tiêu OOV và xử lý tràn vụn lỗi dính/tách từ.
- **Mở rộng từ điển từ đồng âm ngữ cảnh:** Bổ sung dữ liệu huấn luyện chuyên sâu cho các cặp từ dễ nhầm lẫn như *chẩn đoán/chuẩn đoán*, *sơ suất/sơ xuất*.
- **Phát triển tiện ích mở rộng (Browser Extension):** Đóng gói mô hình thành extension trên Chrome/Firefox để kiểm tra chính tả trực tiếp khi soạn thảo.

8. Tổng kết

- Xây dựng thành công mô hình **Hierarchical Transformer** siêu nhẹ ($\approx 1\text{M}$ tham số), cho phép suy luận nhanh theo thời gian thực.
- Hiệu năng thực nghiệm ấn tượng: **F1 phát hiện 87,61%** và **End-to-End Recall 74,95%** trên tập kiểm định.
- Đóng gói hoàn chỉnh hệ sinh thái từ pipeline dữ liệu 4,66M mẫu, huấn luyện streaming đến ứng dụng Web Demo tương tác.

Cảm ơn thầy và các bạn đã lắng nghe

Phần hỏi đáp (Q&A)